

GÖRÜNTÜ İŞLEME

Günümüzde en güçlü görüntü işleme modelleri, [evrişimli sinir ağlarına](#) (CNN'ler) dayanmaktadır. Bu nedenle, son teknoloji yöntemler tipik olarak, özellikle insan veya nesne pozunu algılama sistemleri için uyarlanmış CNN mimarisinin tasarlanmasına dayanır.

Aşağıdan yukarıya yöntemler, önce her bir vücut eklemi tahmin eder ve ardından benzersiz bir poz oluşturmak için bunları gruplandırır. **Yukarıdan aşağıya yöntemler**, önce bir kişi dedektörünü çalıştırır ve algılanan sınırlayıcı kutular içindeki vücut eklemlerini tahmin eder.

2D İnsan Pozu Tahmini Nedir?

2D insan pozunu tahmini, görüntüler ve videolar gibi görsellerden insan vücudunun kilit noktalarının 2B konumunu veya uzamsal konumunu tahmin etmek için kullanılır. Geleneksel 2D insan pozunu tahmin yöntemleri, tek tek vücut parçaları için farklı el yapımı [özellik çıkarma](#) teknikleri kullanır. Bazı popüler 2B insan pozunu tahmin yöntemleri arasında [OpenPose](#), CPN, AlphaPose ve HRNet bulunur.

3D İnsan Pozu Tahmini Nedir?

3B insan pozunu tahmini, 3B uzayda vücut eklemlerinin konumlarını tahmin etmek için kullanılır. 3B pozun yanı sıra, bazı yöntemler görüntülerden veya videolardan 3B insan ağına da kurtarır. Bu alan, insan vücudu ile ilgili kapsamlı 3D yapı bilgisi sağlamak için kullanıldığından son yıllarda büyük ilgi görmüştür. Birden fazla bakış açısı veya ek sensörler (IMU veya LiDAR) kullanılarak, çok zorlu bir görev olan bilgi füzyon teknikleriyle 3D poz tahmini uygulanabilir. 2B insan veri kümeleri kolayca elde edilebilirken, doğru 3B poz [görüntü açıklamalarını](#) toplamak zaman alıcıdır ve manuel etiketleme pratik ve pahalı değildir.

İnsan vücudu modellemesi için üç tür model vardır.

Kinematik Model

İskelet tabanlı model olarak da adlandırılan Kinematik Model, 2B ve 3B poz tahmini için kullanılır. Bu esnek ve sezgisel insan vücudu modeli, insan vücudu yapısını temsil etmek için bir dizi eklem pozisyonu ve uzuv yönelimi içerir. Bu nedenle, iskelet pozunu tahmin modelleri, farklı vücut bölümleri arasındaki ilişkileri yakalamak için kullanılır. Bununla birlikte, kinematik modeller doku veya şekil bilgilerini temsil etmede sınırlıdır.

Düzlemsel Model

Düzlemsel Model veya kontur tabanlı model, 2B poz tahmini için kullanılır. Düzlemsel modeller, bir insan vücudunun görünümünü ve şeklini temsil etmek için kullanılır. Genellikle vücut parçaları, insan vücudu hatlarına yaklaşan birden fazla dikdörtgenle temsil edilir. Popüler bir örnek, temel bileşen analizini kullanarak tam insan vücudu grafiğini ve silüet deformasyonlarını yakalamak için kullanılan [Aktif Şekil Modeli'dir](#) (ASM).

Hacimsel Model

3D poz tahmini için hacimsel bir model kullanılır. 3B insan ağınlı kurtarmak için derin öğrenme tabanlı poz analizi için kullanılan çok sayıda popüler 3B insan vücudu modeli mevcuttur. Örneğin, [GHUM](#) ve [GHUML\(ite\)](#), istatistiksel ve eklemli 3D insan vücudu şekillerini ve pozlarını modellemek için 60.000'den fazla insan konfigürasyonunun tam vücut taramalarından oluşan yüksek çözünürlüklü bir veri seti üzerinde eğitilmiş, tamamen eğitilebilir uçtan uca derin öğrenme boru hatlarıdır.

Derin Öğrenme ile İnsan Poz Tahmini

Açık Poz

Gerçek zamanlı ve çok kişili poz tahmini için en popüler aşağıdan yukarıya yaklaşımlardan biridir. [OpenPose](#), vücut, ayak, el ve yüz kilit noktalarını tespit etmede yüksek doğruluk elde etmek için uygun olan açık kaynaklı bir çerçevedir. OpenPose'un bir avantajı, kullanıcılara kamera alanlarından, web kameralarından ve diğerlerinden, daha da önemlisi [gömülü sistem uygulamalarından](#) (örneğin, CCTV kameraları ve sistemleriyle entegrasyon) kaynak görüntüleri seçme esnekliği sağlayan bir API olmasıdır.

CUDA GPU'lar, OpenCL GPU'lar veya yalnızca CPU cihazları gibi farklı donanım mimarilerini destekler. Hafif sürüm, uç cihazlarla gerçek zamanlı olarak cihaz üzerinde işleme ile Edge çıkarım uygulamaları için yeterince verimlidir.

HRNet

[Yüksek Çözünürlüklü Ağ \(HRNet\)](#), insan pozu tahmini için bir sinir ağıdır. Bir görüntüdeki belirli nesne veya kişi için kilit noktalar (eklemler) olarak bildiklerimizi bulmak için görüntü işleme problemlerinde kullanılan bir mimaridir. Bu mimarinin diğer mimarilere göre bir avantajı, mevcut yöntemlerin çoğunun, yüksek-düşük çözünürlüklü ağların kullanımıyla ilgili düşük çözünürlüklü

temsillerden duruşların yüksek çözünürlüklü temsilleriyle eşleşmesidir.

Bu önyargının yerine, sinir ağı, duruşları tahmin ederken yüksek çözünürlüklü temsilleri korur.

Örneğin, bu HRNet mimarisi, televizyonda yayınlanan sporlarda insan duruşunun algılanmasına yardımcı olur.

Derin Poz

[DeepPose](#), [derin sinir ağlarının](#) (DNN) kullanımından yararlanan bir insan pozu tahmincisidir.

DeepPose'un DNN'si tüm eklemleri yakalar, bir havuzlama katmanını, bir evrişim katmanını ve bu katmanların bir parçasını oluşturmak için tam bağlı bir katmanı menteşeler.

Poz Ağı

Bu, tarayıcılar veya mobil cihazlar gibi hafif cihazlarda çalışacak TensorFlow.js üzerine kurulu bir poz tahmin mimarisidir. Bu nedenle [PoseNet](#), tek **bir pozu** veya **birden fazla pozu** tahmin etmek için kullanılabilir.

Yoğun Poz

Bu, bir RGB görüntüsünün tüm insan piksellerini insan vücudunun 3B yüzeyine eşleyen bir poz tahmin tekniğidir. [DensePose](#), tekli ve çoklu poz tahmin problemleri için de kullanılabilir.

OpenPifPaf (Açık Dosya)

[OpenPifPaf](#), görüntülerde veya videolarda insan vücudunun parçalarını tanımlamayı ve yerelleştirmeyi içeren poz anlama için açık kaynaklı bir bilgisayarla görme kitaplığı ve çerçevesidir. [PyTorch](#) derin öğrenme çerçevesi üzerine inşa edilmiştir ve doğru ve verimli poz tahmini elde etmek için çok görevli bir öğrenme yaklaşımı kullanır. OpenPifPaf, kullanım kolaylığı, sağlamlığı ve oklüzyon ve dağınık arka planlar gibi zorlu hareket izleme senaryolarını ele alma yeteneği nedeniyle popülerlik kazanmıştır.

İnsan Aktivitesi Tahmini

Poz tahmininin oldukça açık bir uygulaması, insan aktivitesini ve hareketini izlemek ve ölçmektir.

DensePose veya PoseNet gibi mimariler genellikle aktivite, hareket veya yürüyüş tanıma için kullanılır. Poz tahmini kullanımı yoluyla insan etkinliği izleme örnekleri şunları içerir:

- Oturma hareketlerini algılamak, el hareketlerini tanımak veya yüz ifadelerini analiz etmek için uygulama
- Futbol, basketbol, kriket vb. alanlardaki oyuncuların ve sporcuların yapay zeka tabanlı analizi.
- Dans tekniklerini analiz etmek için uygulamalar (örneğin, bale danslarında)
- Tıbbi uygulamalarda ameliyatların kalitesini değerlendirmek için bilgisayarlı görme sistemleri.
- Egzersizlerin yürütme şeklini tespit etmek ve tekrarları saymak için fitness uygulamaları.
- Tam vücut/işaret dili iletişimi (örneğin, trafik polislerinin işaretleri).
- [Düşen insanları](#) veya belirli hastalıkların sürecini tespit etmek için akıllı uygulamalar.

Başlarken

Kurumsal bilgisayarlı görü platformu Viso Suite, poz tahmin sistemlerinin hızlı ve ölçekli bir şekilde oluşturulmasını ve sunulmasını mümkün kılar. Uçtan uca çözüm, küresel liderler tarafından çeşitli [yapay zeka donanımlarına](#) ve en yeni işlemcilere sahip ortak CCTV veya USB kameraları kullanarak gerçek dünya poz tahmin uygulamalarını uygulamak için kullanılır.

Sapiens: Meta'dan İnsan Görme Modelleri Vakfı

Meta'dan Rawal ve arkadaşlarının temel İnsan Görme Modelleri ailesi olan **Sapiens**, 2D poz tahmini, **vücut parçası segmentasyonu**, **derinlik tahmini ve yüzey normal tahmini** gibi insan merkezli görevler için son teknoloji sonuçlar elde ediyor. Meta'dan Rawal ve arkadaşlarının temel İnsan Görme Modelleri ailesi olan **Sapiens**, 2D poz tahmini, **vücut parçası segmentasyonu**, **derinlik tahmini ve yüzey normal tahmini** gibi insan merkezli görevler için son teknoloji sonuçlar elde ediyor.

Göreve Özel İnce Ayar

Sapiens modelleri, kodlayıcı için önceden eğitilmiş ağırlıklarla başlatılır ve kod çözücü, rastgele ağırlıklarla başlatılan göreve özgü bir kafadır. İnce ayar sırasında hem kodlayıcı hem de kod çözücü uçtan uca eğitilir.

1. 2D Poz Tahmini

Sınırlayıcı kutularla birlikte üç kanalın giriş görüntüsü, kodlayıcıya yamalar olarak geçirilir. Model yukarıdan aşağıya bir yaklaşım izler, önce ROI (yani kişi) tespit edilir ve poz için kilit noktalar tahmin edilir. Sapiens poz tahmin modeli: K anahtar noktaları için poz elde edilen K ısı haritalarını belirlemek için her bir anahtar noktanın ısı haritalarını kullanır.

Not: [İsı Haritası'ndaki](#) (2B matris) her değer, belirli bir [anahtar noktanın](#) belirli bir uzamsal konumda olma olasılığını temsil eder.

Eğitim veri seti, 243'ü özellikle yüz kilit noktaları ve 40'ı el anahtar noktaları için olmak üzere 308 tam vücut anahtar noktası içerirken, diğer poz tahmin veri kümelerinde genellikle 68 yüz anahtar noktası bulunur. Bunlar göz, dudak, burun ve kulak çevresinde daha iyi temsile yardımcı oldu.

2. Vücut Parçası Segmentasyonu

Bu görevin amacı, giriş görüntüsündeki (I) her pikseli kol, bacak, gövde vb. gibi C sınıflarına (Çok Sınıflı Segmentasyon) sınıflandırmaktır, Her piksel için model, pikselin tüm vücut kısımları üzerinde belirli bir sınıfa ait olduğuna dair bir olasılık haritası tahmin eder. Bu görevde, tahmin edilen ve temel gerçek parçalar segmentasyon maskeleri arasında ağırlıklı çapraz entropi kaybı kullanıldı. Kullanılan veri kümesi, 4k çözünürlükte manuel olarak oluşturulan 0,1 M ek açıklamalar içerir. Model, 28 farklı vücut bölümünü tahmin edebilir ve uzuvların, bacakların, dudakların vb. daha ince ayrıntılarını ana hatlarıyla belirtir.

3. Derinlik Tahmini

[Derinlik tahmini](#) mimarisi segmentasyona benzer, ancak kod çözücünün çıkış kanalı 1 olarak değiştirilir. Çünkü derinlik tahmini, çıktının çok sınıflı olasılık haritaları yerine her piksel için tek bir derinlik değeri olduğu bir [regresyon](#) görevidir. Göreli derinliği hesaplamak için, derinlik değeri maksimum ve minimum piksel değeri kullanılarak 0 ile 1 arasında normalleştirilir. Etkili eğitim için 600 yüksek çözünürlüklü insan taramasından elde edilen 0,5 milyon [sentetik](#) görüntü kullanılır. Sahnenin içine sanal bir kamera yerleştirilir ve 4K çözünürlükte çeşitli derinlik haritaları elde etmek için odak uzaklığı, [çeviri, döndürme](#) ve [kamera kalibre edilir](#).

4. Yüzey Normal Tahmini

Bir insan vücudunun normal bir yüzeyi, vücudun belirli bir noktasında yüzeye dik olan bir vektördür. Yüzeyin bir 3B uzayda yönlendirilmesini ifade eder. Yüzey normalleri, gerçekçi yansımalar oluşturmak için ışığın vücudun yüzeyiyle nasıl etkileşime girdiğini belirlemede özellikle yararlıdır. Yüzey normalleri, gerçekçi yansımalar oluşturmak için ışığın vücudun yüzeyiyle nasıl etkileşime girdiğini belirlemede özellikle yararlıdır.

YOLO-NAS Pose

. Bu Pose modeli, gecikme ve doğruluk arasında mükemmel bir denge sunar. YOLO-NAS Pose, geleneksel Poz Tahmin modellerine kıyasla işleri farklı şekilde yapar. Önce kişiyi tespit etmek ve ardından pozunu tahmin etmek yerine, kişiyi ve pozunu tek bir adımda, aynı anda algılayabilir ve tahmin edebilir. Arama için hiper parametreler şunlardır:

- Hem poz hem de kutu regresyon yolları için Conv-BN-Relu bloklarının sayısı.
- Her iki yol için ara kanal sayısı
- Poz/kutu regresyonu için paylaşılan bir kök veya farklı gövdeler arasındaki karar

YOLO-NAS Pose modelleri, COCO Val 2017 Veri Seti üzerinde değerlendirilir. Modelin doğruluğu ve gecikme süresi son teknoloji ürünüdür. Nano model en hızlısıdır ve bir T4 GPU'da 425 fps'ye kadar çıkarıma ulaşır. Bu arada, büyük model 113 fps'ye kadar ulaşabilir.

Uç dağıtımına bakarsak, nano ve orta modeller sırasıyla 63 fps ve 48 fps'de gerçek zamanlı olarak çalışmaya devam edecek. Ancak Jetson Xavier NX'te kullanılan orta ve büyük modellere baktığımızda, hız azalmaya başlıyor ve sırasıyla 26 fps ve 20 fps'ye ulaşıyor. Bunlar hala mevcut en iyi sonuçlardan bazıları.

Poz Modelleri Nasıl Eğitildi?

YOLO-NAS Poz Kaybı İşlevi

Modelin her iki görevi de etkili bir şekilde öğrendiğinden emin olmak için Deci, eğitimde kullanılan kayıp fonksiyonlarını geliştirdi. Atanan kutular için yalnızca [IoU \(Birleşim Üzerinden Kesişim\)](#) puanını dikkate almak yerine, tahmin edilen kilit noktaları gerçek olanlarla karşılaştıran [Nesne Anahtar Noktası Benzerliği \(OKS\)](#) puanını da dahil ettik. Bu değişiklik, modeli hem sınırlayıcı kutular hem de poz tahmini için doğru tahminler yapmaya teşvik eder.

Ayrıca, geleneksel L1/L2 kayıp yöntemlerini aşan doğrudan OKS regresyon tekniği kullanılmıştır. Bu yaklaşım çeşitli avantajlar sunar:

- IoU kutusuna benzer şekilde 0 ila 1 aralığında çalışır ve pozların ne kadar benzer olduğunu gösterir.
- Belirli kilit noktalara açıklama eklemeye değişen zorluk seviyelerini dikkate alır. Her kilit nokta, ek açıklama ve veri kümesi özelliklerinin doğruluğunu yansıtan benzersiz bir sigma puanı ile ilişkilendirilir. Puan, modelin yanlış tahminler yaptığı için ne kadar cezalandırılacağını belirler.
- Doğrulama metriğiyle uyumlu bir kayıp işlevi kullanarak, metriğin hedeflenmesine ve optimizasyonuna olanak tanır.

Eğitim Hiperparametreleri

YOLO-NAS Pose, YOLO-NAS modeliyle benzer bir temel yapı kullandığından, son eğitime devam etmeden önce modelimizin omurgasını ve boynunu başlatmak için [YOLO-NAS'in önceden eğitilmiş ağırlıkları](#) kullanıldı. İşte eğitim hiperparametreleri:

- Eğitim Donanımı: PyTorch 2.0 ile 8 NVIDIA GeForce RTX 3090 GPU kullanıldı.

- Eğitim Programı: Eğitim, 1000 döneme kadar yürütüldü ve son 100 dönemde performansta herhangi bir gelişme olmazsa erken durduruldu.
- Optimize Edici: Kosinüs LR (Öğrenme Oranı) azalması ile AdamW kullanıldı ve eğitimin sonuna doğru LR'yi 0,05 kat azalttı.
- Ağırlık Azalması: Önyargı ve BatchNorm katmanları hariç olmak üzere 0.000001'lik bir ağırlık azalma faktörü uygulandı.
- EMA (Üstel Hareketli Ortalama) Bozulması: EMA bozunması için 50 beta faktörü kullanılır.
- Görüntü Çözünürlüğü: Görüntüler, maksimum kenar uzunluğu 640 piksel olacak şekilde işlendi ve (127, 127, 127) dolgu rengiyle 640×640 çözünürlüğe kadar dolduruldu.

Mozaik veri büyütme, rastgele 90 derecelik döndürmeler ve renk büyütme gibi büyütme AP'yi 2 kat daha da geliştirdi.

Anahtar Nokta Algılamada Nesne Anahtar Noktası

Benzerliği

Anahtar nokta algılamının doğruluğunu ölçmek için kullanılan özel bir ölçüm olan Nesne Anahtar Noktası Benzerliği (OKS) kavramını girin. OKS, ölçek, etiketlenmemiş kilit noktalar ve ek açıklamalardaki belirsizlik gibi faktörleri göz önünde bulundurarak tahmin edilen kilit noktaları temel gerçeğe karşılaştırmak için standartlaştırılmış bir yol sağlar.

Anahtar Nokta Algılamada Nesne Anahtar Noktası

Benzerliği (OKS)

Alan tabanlı bir hesaplama olan IoU'dan farklı olarak, kilit noktalar için mesafe tabanlı bir yaklaşımın oluşturulması gerekir. Bu nedenle, MS-COCO, iki anahtar nokta kümesi arasında bir benzerlik ölçüsü oluşturmanın bir yolu olarak nesne anahtar nokta benzerliğini (OKS) önerdi.

Anahtar nokta benzerliği (KS), **anahtar noktası başına** hesaplanır. Temel gerçek ile tahmin edilen anahtar nokta arasındaki Öklid mesafesinin, standart sapma **sk** ile **normalleştirilmemiş bir Gauss dağılımı** üzerinden geçirilmesiyle hesaplanır, burada **s**, temel olarak nesnenin parçalı alanının karekökü olan ölçektir ve **k**, anahtar nokta başına sabittir.

CenterNet: Nokta Olarak Nesneler – Çapasız Nesne

Algılama Açıklaması

Çapasız nesne algılama, hızı ve diğer görüntü işleme görevlerine genelleştirilebilirliği nedeniyle güçlüdür.

Çapa Tabanlı Nesne Algılama Nedir?

Teklif olarak önceden tanımlanmış sınırlayıcı kutuları (çapalar) kullanan derin öğrenme tabanlı bir nesne algılama yöntemi, çapa tabanlı nesne algılama olarak bilinir.

Çapalara bir etiket atama stratejisiyle sınıf etiketleri atanır. Örneğin, saf bir etiket atama stratejisinde, bazı temel gerçeklere sahip bir çapanın maksimum **IoU'su** (Birleşim Üzerinden Kesişme) **0,5'ten** büyükse, çapaya temel doğruluk etiketi atanacaktır.

Çapa tabanlı nesne algılamada model, çapa kutularının sınıf etiketlerini ve çapanın aşağıdaki gibi temel doğruluk nesneleriyle eşleşecek şekilde nasıl ayarlanması gerektiğini tahmin eder.

Çapasız Nesne Algılama Nedir?

Bağlayıcısız nesne algılama, sınırlayıcı kutuyu doğrudan tahmin eder, ancak görüntüdeki bazı sabit başvurulara göre bunu tahmin eder.

Örneğin, aşağıdaki gibi **300 x 300** boyutunda bir resim düşünün (**şek. 4**). Eşit olarak **6 x 6** ızgara hücrelerine bölünmüştür. Zemin hakikat merkezi, ızgara hücrelerinden birine düşecek. Bu nedenle, nesnenin **genişliğini**, **yüksekliğini** ve **ızgara hücresi merkezinden merkez sapmasını** tahmin etmekten yalnızca ızgara hücresi sorumludur.

Anchor Free, Anchor-b destekli nesne algılamadan daha mı iyi?

Çapa tabanlı yöntemin ilk başarısı, daha fazla araştırmaya yol açtı ve bu da onu çapasız nesne algılamadan daha doğru hale getirdi. Bununla birlikte, çapasız nesne algılamadaki son başarı, onu doğruluk açısından çapa tabanlı yöntemle eşdeğer hale getirdi.

Aşağıda, çapa tabanlı çapa içermeyen yöntemlerin birkaç avantajı verilmiştir:

1. Uygun ankraj kutularını (şekil ve boyut olarak) bulmak, mükemmel bir ankraj tabanlı nesne algılama modelini eğitmek için çok önemlidir. Uygun ankrajları bulmak karmaşık bir sorundur ve hiper parametre ayarlaması gerektirebilir.
2. Daha fazla çapa kullanmak, çapa tabanlı nesne algılamada daha iyi doğruluk sağlar, ancak daha fazla çapa kullanmanın bir maliyeti vardır. Modelin daha karmaşık bir mimariye ihtiyacı vardır ve bu da daha yavaş çıkarım hızına yol açar.
3. Çapasız nesne algılama daha genelleştirilebilir. Nesneleri, anahtar nokta algılama, 3B nesne algılama vb. için kolayca genişletilebilen noktalar olarak tahmin eder. Ancak, çapa tabanlı nesne algılama çözümü yaklaşımı, sınırlayıcı kutu tahmini ile sınırlıdır.

PyTorch'ta Keypoint RCNN kullanarak İnsan Pozu

Tahmini

Keypoint-RCNN adlı bir insan içeren görüntülerde anahtar noktaları bulmak için böyle bir algoritmayı tartışacağız. Kod, **Torchvision** kitaplığı kullanılarak Pytorch'ta yazılmıştır.

Vücut eklemlerinin duruşlarını analiz ederek doğru vücut pozunu elde etmeniz için size rehberlik edebilecek kişisel bir fitness eğitmeni oluşturmak istediğinizi varsayalım. İşte bu noktada Poz Tahmini devreye giriyor.

Anahtar Nokta Algılama fikri, bir görüntüdeki ilgi noktalarını veya önemli konumları tespit etmektir. Bunlar şunlar olabilir:

- Yüzdeki yer işaretleri (burun ucu, göz köşeleri, yüz sınırı vb.)
- veya bir kişide vücut eklemleri (omuzlar, bilekler, ayak bilekleri)
- veya bir görüntüdeki köşeler ve lekeler

Anahtar Nokta Algılama Uygulamaları

Anahtar Nokta Algılama geniş bir uygulama yelpazesine sahiptir. İşte birkaçı:

Egzersiz sırasında bir kişinin doğru vücut duruşlarını belirleme

Vücut duruşu kontrolü, duruşu tahmin etmek için farklı kilit noktalar arasındaki açılar bulmayı gerektirir. Bu bilgilere dayanarak, egzersiz sırasında farklı kemiklerin (kollar, bacaklar, sırt vb.) açılarının ve yüksekliklerinin doğru olup olmadığı kontrol edilebilir.

Torchvision'ın Anahtar Nokta Algılama API'si

Torchvision, algılama modülünde önceden eğitilmiş bir Anahtar Nokta Algılama modeline sahiptir. Model, ResNet-50 FPN (Feature Pyramid Network) omurgasının üzerine inşa edilmiştir. [Özellik Piramit Ağı](#), bilgileri birden çok düzeyde korumak için özellik haritalarını birden çok ölçekte birleştirme kavramıdır. Bu omurga mimarisi aynı zamanda RetinaNet'te de kullanıldı ([Odak Kaybını](#) tanıttı). Keypoint RCNN, Nesne Algılama, Segmentasyon ve Görüntü Altyazısı için farklı açıklama türleri sunan [MS-COCO](#) (Bağlamdaki Ortak Nesneler) veri kümesi üzerinde eğitilmiştir. Anahtar Nokta Algılama da aynı listede yer alır.

Başlangıçta COCO'nun Algılama ve Segmentasyon için sınıflar sunduğunu unutmayın. Ancak, Anahtar Nokta Algılama için ek açıklamalar yalnızca kişi sınıfı için sunulur. Torchvision'da

bulunan Keypoint-RCNN, bir kişideki kilit noktaları belirlemek için özel olarak eğitilmiştir, böylece üzerinde çıkarım yaparsınız.

OpenPose : İnsan Pozu Tahmin Yöntemi

OpenPose, tek bir görüntüde insan vücudu, el, yüz ve ayak tuş noktalarını (toplam 135 anahtar noktası) birlikte algılayan ilk gerçek zamanlı çok kişili sistemdir. Carnegie Mellon Üniversitesi'ndeki araştırmacılar tarafından önerildi. Python kodu, C++ uygulaması ve Unity Eklentisi şeklinde yayınladılar

Mimarlık:

- İlk adımda, görüntü, kağıttaki girişin özellik haritalarını çıkarmak için temel CNN ağından geçirilir. Bu çalışmada yazarlar VGG-19 ağının ilk 10 katmanını kullanmışlardır.
- Özellik haritası daha sonra Parça Güven Haritaları ve Parça Benzeşim Alanı oluşturmak için çok aşamalı bir CNN işlem hattında işlenir
 - Parça Güven Haritaları:
 - Parça Yakınlığı Alanı
- Son adımda, yukarıda oluşturulan Güven Haritaları ve Parça Yakınlık Alanları, görüntüdeki her bir kişi için pozları elde etmek için açgözlü bir ikili eşleştirme algoritması tarafından işlenir.

Güven Haritaları ve Parça Benzeşim Alanları

Güven Haritaları: Güven Haritası, belirli bir vücut parçasının herhangi bir pikselde bulunabileceğine dair inancın 2B temsidir.

Parça Yakınlığı Alanları: Parça Yakınlığı, görüntüdeki farklı kişilerin uzuvlarının konumunu ve yönünü kodlayan bir dizi 2B vektör alanıdır.

Parça Yakınlık Alanları:

Parça yakınlık alanı gereklidir, özellikle çok kişili poz tespitinde, doğru vücut kısımlarını vücutuna haritalamamız gerekir. Çünkü birden fazla kişi için birden fazla baş, el, omuz vb. vardır. Bu nedenle, bazen birbirine yakın bir şekilde gruplandırıldıklarında ayırt etmek zorlaşır. PAF, aynı kişiye ait olan vücudun farklı bölümleri arasında bir bağlantı sağlar. Vücut parçaları arasında daha güçlü bir PAF bağlantısı, bu vücut parçalarının aynı kişiye ait olma ihtimalinin yüksek olduğunu temsil eder.

human_pose_detection

MediaPipe, arka uçta TensorFlow lite kullanır. Bir dedektör kullanmak, önce çerçeve içindeki kişiyi (ROI) bulur. Ardından, ROI kırılmış çerçevesini INPUT olarak kullanır ve ROI içindeki yer işaretlerini/anahtar noktaları tahmin eder. mediaPipe poz tahmincisi toplam 33 anahtar nokta algılar.

MediaPipe poz tahmini, tek bir 3B poz tahmincisidir. Her yer işareti için x, y ve z koordinatlarını algılar. Z eksenini temel olarak bir dönüm noktasının derinliği hakkında bilgidir. Bu, yer işaretlerinin diğer yer işaretlerine göre kameradan ne kadar uzakta veya yakın olduğu anlamına gelir.

MediaPipe Pose, ML Kit Pose Detection API'yi de destekleyen BlazePose araştırmamızı kullanarak RGB video karelerinden tüm vücutta 33 3D yer işareti ve arka plan segmentasyon maskesi çıkaran, yüksek kaliteli vücut pozunu takibi için bir makine öğrenimi çözümüdür. Mevcut son teknoloji yaklaşımlar, çıkarım için öncelikle güçlü masaüstü ortamlarına dayanırken, yöntemimiz çoğu modern cep telefonunda, masaüstü / dizüstü bilgisayarda, python'da ve hatta web'de gerçek zamanlı performans sağlar.

İnsan pozunu algılama kategorileri:

- 1. 2B poz tahmini: 2B poz tahmininde, bir görüntüdeki her yer işareti için yalnızca x ve y koordinatları tahmin edilir. İskeletin açıları veya bir nesnenin veya insan örneğinin dönüşü veya yönü hakkında herhangi bir bilgi vermez.**
- 2. 3D poz tahmini: 3D poz tahmini, bir insanın spiral konumunu tahmin etmemizi sağlar. Her yer işareti için x, y ve z koordinatlarını verir. 3d poz tahmini ile bir insan iskeletinin her bir eklemine açıyı belirleyebiliriz.**
- 3. Sert poz tahmini: Rijit poz tahmini, 6D poz tahmini olarak da bilinir. İnsan duruşunun yanı sıra bir insan örneğinin dönüşü ve yönü hakkında tüm bilgileri sağlar.**
- 4. Tek poz tahmini: Tek poz tahmin modelinde, bir görüntüde yalnızca bir insanın pozunu tahmin edilebilir.**
- 5. Çoklu poz tahmini: Çoklu poz tahmininde, bir görüntüde aynı anda birden fazla insan pozunu tahmin edilebilir.**

